[Audio] Demucs의 계보

JIN · 2024년 4월 29일

팔로우 0

MIR Source Separation

1. Demucs

input : raw waveform

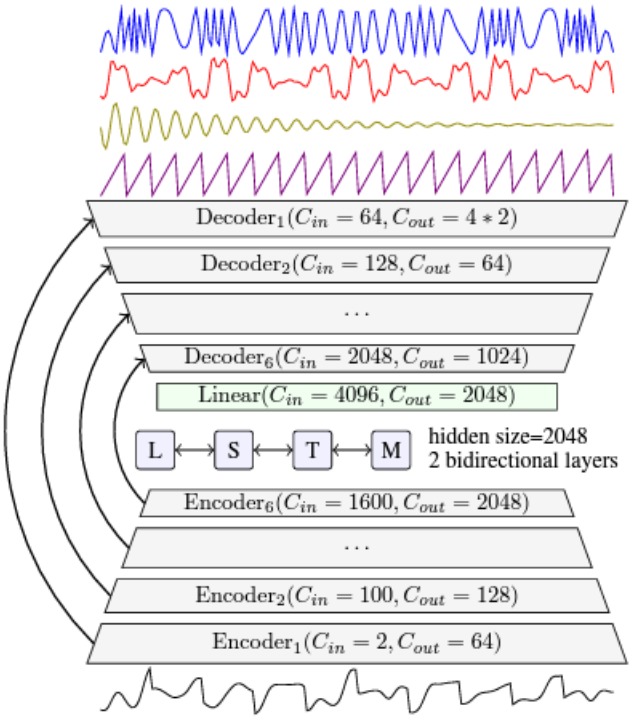
output : 각 악기 소스 별 waveform 생성 (drum/bass/others/vocal)

`U-net 구조` : convolution encoder, wide transposed convolution 기반의 decoder

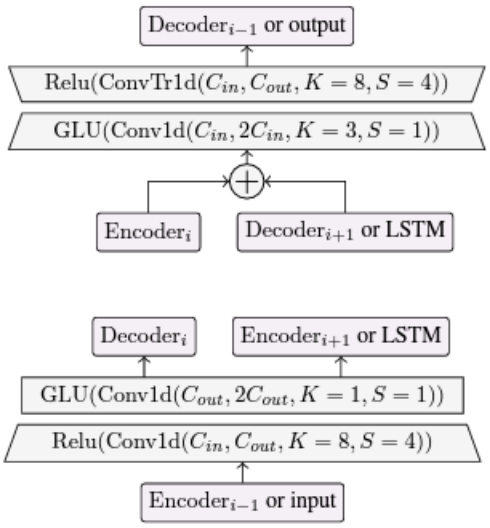
- encoder와 decoder 사이에 skip connection → original signal에 직접적인 접근이 가능하게 함, input 상에서 output으로 직접 transfer함
- U-net과의 차이점 : 선형 보간이 아닌 convolution of stride of 1 사용 (적은 계산량)
- 주요 특징
  - bi-LSTM(중요), 깊이에 비례하는 채널수, 마스킹 허용하는 활성화 함수(GLU)
  - L1 손실을 주로 씀 (L1과 L2 사이에 큰 차이 없음)
  - 초기화의 중요성
  - 소스 분리 모델은 시간 동치성 (time equivariant, input을 이동시킨만큼 output도 이동됨)가 중요함 → demucs는 자연적으로 만족 x → 따라서 `shift trick1` 제안

- shift trick1 : input mixture x를 S 샘플로 무작위 이동함 → 반대의 이동을 적용한 후 각각에 대한 모델 예측을 평균냄

MusDB로 학습 (drum/base/others/vocal로 이루어진 150개 곡)



(a) Demucs architecture with the mixture waveform as input and the four sources estimates as output. Arrows represents U-Net connections.



(b) Detailed view of the layers Decoder_i on the top and Encoder_i on the bottom. Arrows represent connections to other parts of the model. For convolutions, C_in (resp C_out) is the number of input channels (resp output), K the kernel size and S the stride.

Figure 2: Demucs complete architecture on the left, with detailed representation of the encoder and decoder layers on the right.

성능 평가는 SDR (Signal to Distortion Ratio, 다른 소스나 아티팩트에 의한 오염된 비율)

피치/템포 증강 : 성능 향상 (사유: 오디오 저하시키지만 오히려 과적합 방지가 됨)

인코더 : CL=2048. 양방향 LSTM. LSTM 시간 위치당 2개의 CL채널 output(=4096)을 가짐. 따라서 CL로의 축소를 위해 linear layer 사용.

디코더 : GLU: 커널 크기 3 → 인접 timestep의 context 제공 → transpose된 컨볼루션의 출력이 시간을 일정하게 하고, stride가 4인 경우에 발생할 수 있는 잠재적인 아티팩트를 줄일 수 있음

	encoder	decoder
number of layer	6	6
each layer kernel	8	8

	encoder	decoder
size each layer stride 특징	4 1x1 convolution kernel size 1, ReLU → 1x1 convolution은 채널을 2배로 늘리고 GLU는 반으로 줄여 일정하게 유지하게 함 encoder 들어오기 전 2배로 upsampling	4 skip connection, 이전 레이어와 합산, 1x1 convolution with GLU → transposed convolution(채널 수 절반으로 줄임) → ReLU decoder 나올 때 2배로 downsampling

단점 : 모델 크기가 너무 큼 → 해결법은 초기 채널 수 줄이기 or DiffQ 양자화 기술을 사용(SDR 손실 없이 줄일 수 있음)

결론 : 베이스, 드럼은 demucs가 우세하나 나머지는 스펙트로그램 기반이 우세

- 스펙트로그램 도메인 모델은 콘텐츠가 주로 고조파이고 빠르게 변할 때 이점을 가지는 것으로 추정되며, 반면 고조파가 없는 경우(드럼) 또는 강한 어택 패턴(베이스)이 있는 경우 음파 도메인이 음악 소스의 구조를 더 잘 보존할 듯함

1-2. Hybrid Demucs

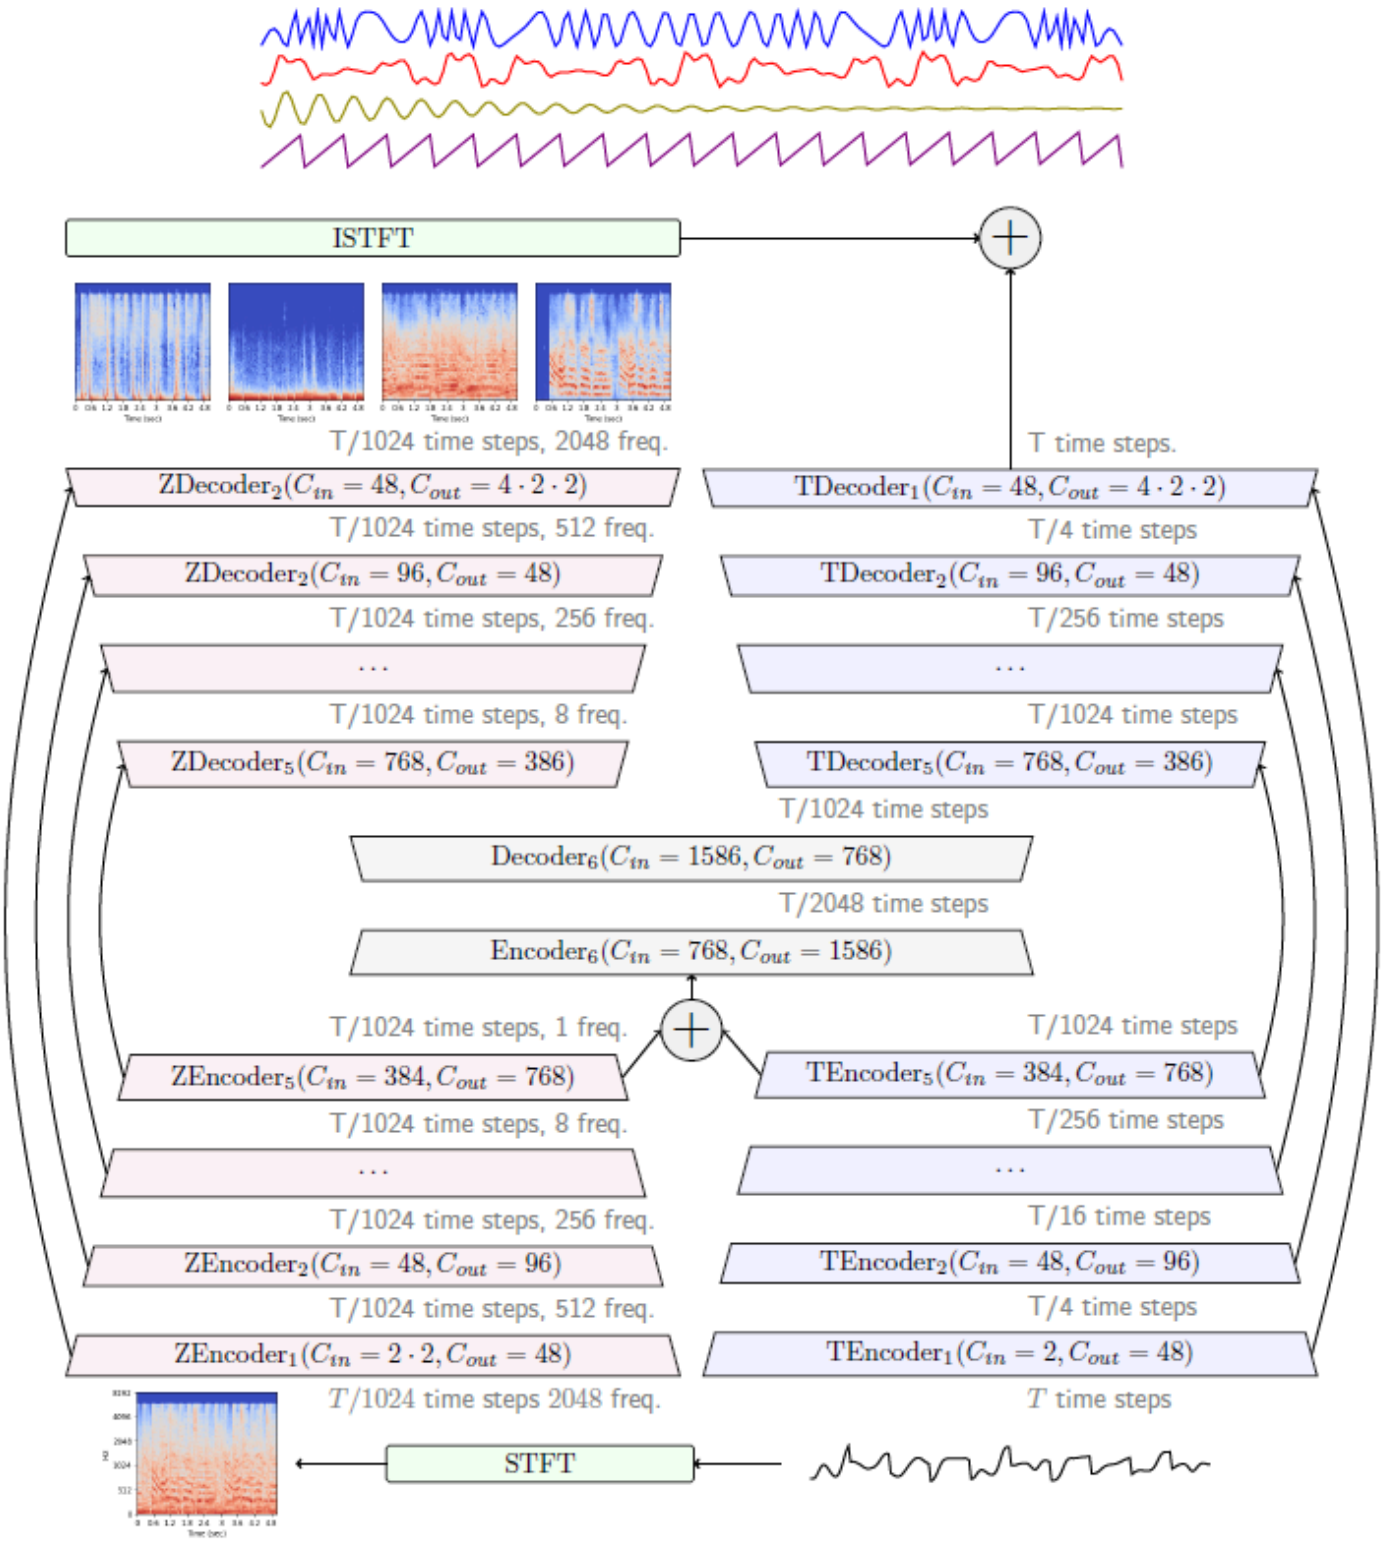
> 기존 demucs는 vocal 분리 때 crunchy static noise에 영향을 받아 좋지 않았음 ⇒ demucs 아키텍쳐 확장하여 `end-to-end hybrid 소스 분리` 방법 : multi domain 분석 및 예측

Hybrid Demucs는 기존의 U-net 아키텍쳐를 확장하여 두 병렬 branch : time (temporal) & frequency (spectral) domain가 있으며, 각 branch에 `skip connection` 이 있는 `이중 U-net 구조`

- time branch
  - input waveform으로부터 표준 demucs처럼 처리

    - 5 layer, time step 수를 줄임 (4의 제곱으로 나눔, 총 1024 나누어짐)
    - ReLU(기존) → GELU로 대체
- spectral branch
    - 4096 time step을 걸친 STFT로 얻은 spectrogram으로부터 얻음
    - hop length = 1024
    - frequency 차원을 줄이기 위해 time branch와 동일한 convolution을 frequency 차원을 따라 적용
    - 5 layer, 각 layer는 주파수를 4로 나누지만 5번째 layer는 8로 나눔.
    - spectral encoder 거친 후에 signal에는 1 frequency만 남음, time branch의 output과 동일한 채널 수 및 sr을 가짐

⇒ temporal and spectral representations는 공유된 encoder/decoder layer을 거쳐 time step을 2로 나눔(커널 크기 4) / 이 output은 temporal and spectral decoder 각각의 input으로 사용 / spectral branch의 output은 ISTFT으로 역변환되고 temporal branch output과 합쳐져 최종 model 예측을 제공



~~ZEncoder3&decoder3 128 freq.안듯함.. 그러면 맞음 !~~

- padding
  - 모든 input 길이에 대해 적절히 align 하기 위해 패딩함
  - MelGAN등을 따라 P = (K-S)/2로 패딩하여 L/S output을 얻음

    - 전체 stride를 맞추면 spectral and temporal representations 길이를 정확히 매치할 수 있음
    - 이 패딩은 STFT와 temporal encoder의 convolution layer에 사용함

- frequency-wise convolution

    - spectral branch에서 frequency-wise convolution 사용하여 매 layer마다 주파수 bin을 4로 나눔
    - 5번째 layer input은 8 frequency bin이고 이를 kernel 8에 no padding convolution사용하여 1로 줄임
    - 시간 축과 달리 musical singal은 frequency 축을 따른 이동에 변함
    - 악기는 특정 pitch 범위를 갖고 보컬은 명확한 형성음을 가짐. 따라서 convolution 적용 전 frequency의 embedding 주입을 제안함.
        - 초기 임베딩을 smooth하게 해 가까운 frequency가 유사한 임베딩을 갖게함.
        - 이는 두번째 인코더 레이어 전에 주입됨

- compressed residual branch

    - 기존 demucs encoder인 convolution with ReLU → convolution with GLU에서 두 convolution 사이에 dilated convolution으로 이루어진 2개의 **compressed residual branch** 도입
    - 내부 layer에는 한정된 범위와 local attention을 가진 양방향 LSTM 포함됨
    - 각 branch의 5번째 layer에는 이 convolution만 포함되어 있어 시간 및 스펙트럼 branch가 동일한 모양을 가짐 (compressed residual branch and 1x1 convolution 공유됨)
    - comporessed residual branch 내에서는 모든 컨볼루션이 시간 차원에 대한 것이며, 서로 다른 frequency bin은 별도로 처리.
    - 각 인코더 당 두 개의 comporessed residual branch 있음. 모두 커널 크기3, stride 1, 첫번째 branch dilation 1. 두번째 branch 2. output 차원은 input의 4배 적음, layer normalization + GELU
    - 5&6번째 encoder layer에서는 long range context가 local attention + bi LSTM(2개의 layer)으로 처리됨 → skip connection으로 삽입 → 최대 범위는 200 steps
    - input은 200 time step의 프레임으로 split with 100 time step stride
    - 각 프레임은 병렬 처리. 임의의 time step에 대해 해당 time step이 가장 가장자리에서 멀리 떨어진 frame의 output이 유지
    - 모든 레이어에는 kernel 1인 최종 컨볼루션으로 output 차원이 input의 2배, GLU가 따름

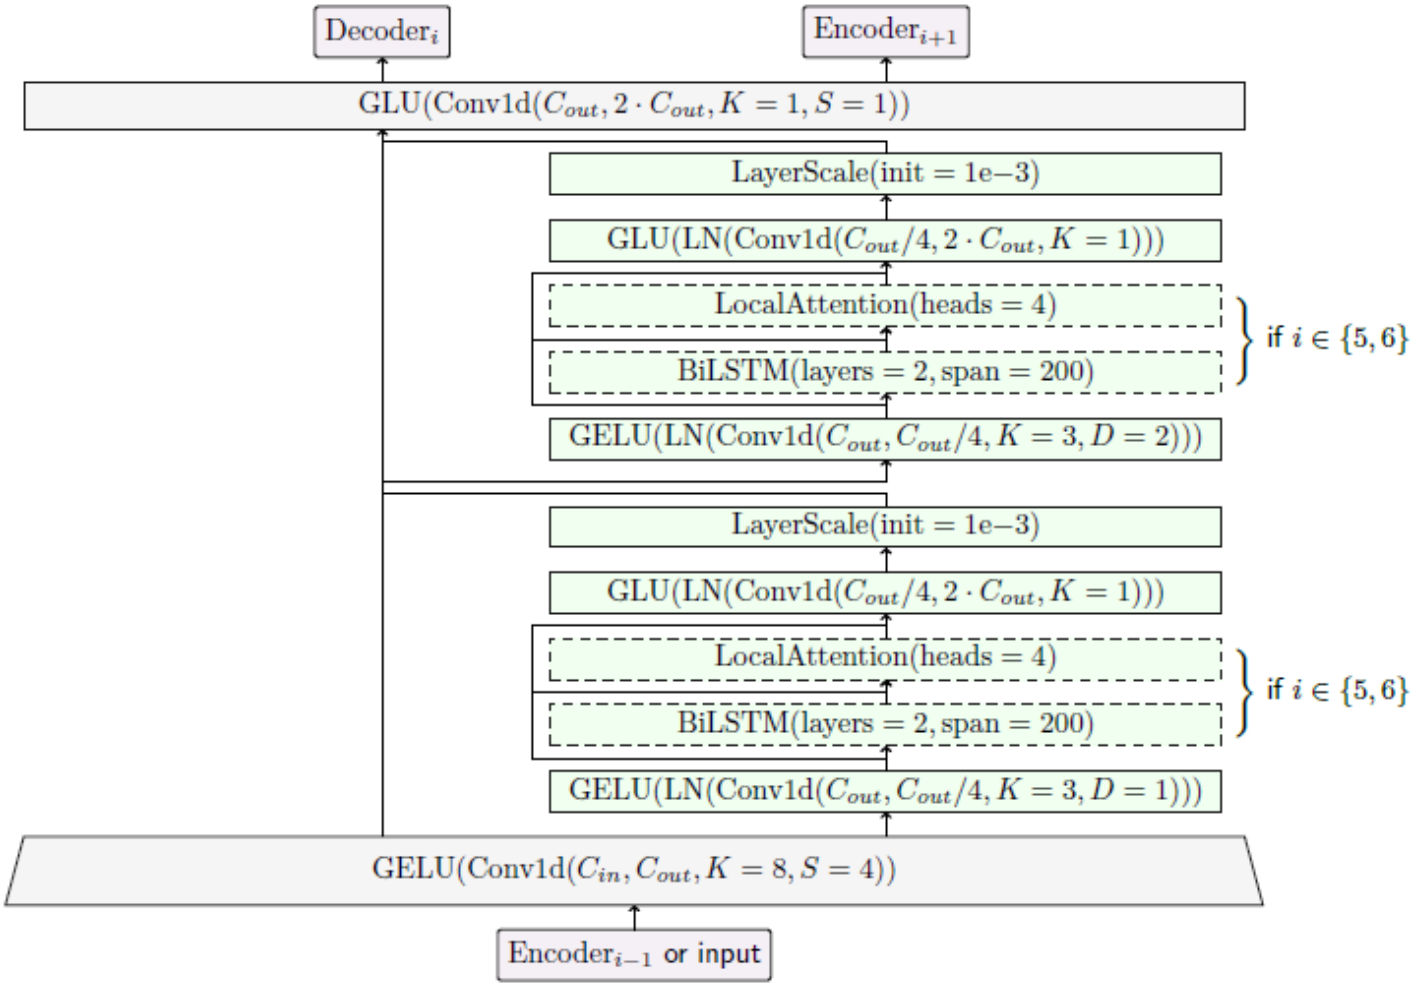


Figure 2: Representation of the compressed residual branches that are added to each encoder layer. For the 5th and 6th layer, a BiLSTM and a local attention layer are added.

- local attention
  - 일반 attention에서 위치 임베딩 대신 컨트롤 가능한 패널티 항으로 대체
- stable train (layer 수가 많아지거나 train size 150곡 추가했을 때 불안정)
  - group normalization : 인코더와 디코더의 레이어 5와 6에 대한 비잔류 합성곱 다음에 그룹 정규화(4개 그룹 사용)를 사용
    - 안쪽 layer에만 사용하여 성능에 영향 x
    - 훈련이 안정적일 때 (only on MusDB)는 성능 개선 없음
    - 훈련이 불안정적이 때 정규화 시 에포크동안 더 많은 훈련 가능
  - singular value regularization
    - 낮은 rank SVD 방법으로 가장 큰 특이값의 더 빠른 근사값을 얻음
    - 훈련이 이미 안정되어 있을 때도 일반화 개선
    - 그러나 불안정성이 완전히 제거되지는 않음
    - 훈련 시간이 더 길어짐
- finetuning (멜로디 라인에 너무 의존하지 않도록 → trackB 사용한 데이터셋)

    - librosa :: 드럼 소스에 비트 추적, 나머지는 크로마그램 추정 적용
    - 시간에 따른 크로마그램을 단일 크로마 분포로 집계하고 두 스템 간의 최대 중첩을 측정하는 데 사용되는 L1 거리에 따라 최적의 음정 이동을 찾음
    - 베이스 라인의 최적 이동은 보컬 및 반주에 대해서도 동일하다고 가정
    - 템포와 첫 비트를 정렬
    - 아티팩트를 제한하기 위해 3 세미톤 미만의 이동 및 15%의 템포 변경이 필요한 경우에만 두 스템이 혼합되도록 허용
- spectrogram branch 대신 residual branch 사용하여 성능 향상
- Hybrid Demucs는 other, vocal SDR을 개선했으나 여전히 다른 모델에 비해 낮음

1-3. Hybrid Transformer Demucs(v4)

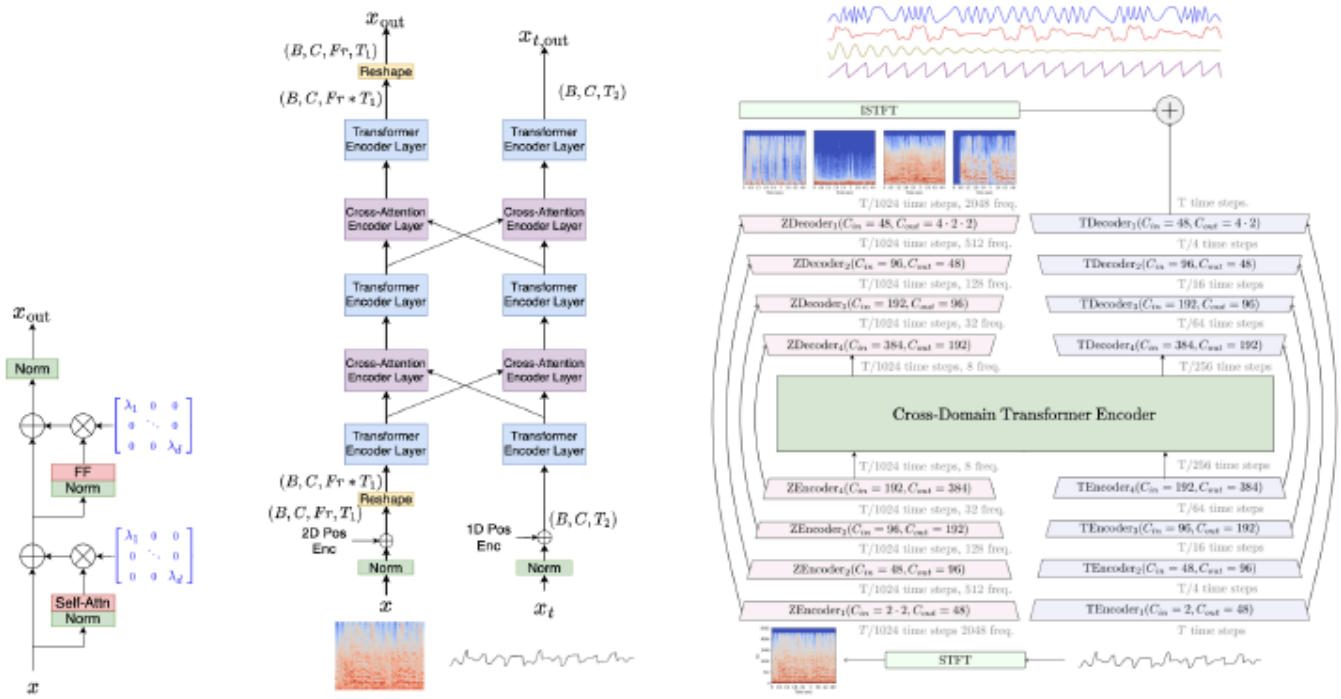
> 기존(=hybrid demucs)의 가장 바깥쪽 4개의 레이어는 유지하고 **인코더와 디코더의 가장 안쪽 2개의 레이어(**로컬 어텐션과 bi-LSTM**)**를 `cross-domain transformer encoder` 로 대체 → 이는 스펙트럼 branch의 2D 신호와 웨이브폼 branch의 1D 신호를 병렬로 처리
>
> Hybrid Demucs는 시간과 주파수 표현을 allign 하기 위해 모델 parameter를 조정해야 했으나, cross-domain transformer encoder는 이질적인 데이터 형태에서 작동할 수 있기 때문에 더 유연함

- Transformer encoder layer
    - 단일 self-attention encoder layer
    - self-attention과 feed forward 전에 정규화, train 안정화를 위해 layer scale과 결합
    - 그 후 time layer norm (모든 토큰이 함께 정규화)
    - input/output 차원은 384
    - 선형 layer 사용

- attention mechanism은 8개 head 가짐
- feed forward network는 transformer 차원의 4배

- Cross-domain encoder layer
  - 동일하나, 다른 도메인과의 corss-attention 사용

- Cross-domain transformer encoder
  - spectral / temporal domain에서 transformer encoder layer와 cross-attention encoder layer 교차됨(interleave)
  - 각 도메인 input에 1D/2D sinusoidal 인코딩 추가 후 spectral domain은 reshape (시퀀스로 처리하기 위해서)



(a) Transformer Encoder Layer

(b) Cross-domain Transformer Encoder of depth 5

(c) Hybrid Transformer Demucs

Fig. 1: Details of the Hybrid Transformer Demucs architecture. (a): the Transformer Encoder layer with self-attention and Layer Scale [6]. (b): The Cross-domain Transformer Encoder treats spectral and temporal signals with interleaved Transformer Encoder layers and cross-attention Encoder layers. (c): Hybrid Transformer Demucs keeps the outermost 4 encoder and decoder layers of Hybrid Demucs with the addition of a cross-domain Transformer Encoder between them.

- Sparse HT Demucs
  - 시퀀스 길이가 증가함에 따라 메모리 소비 및 어텐션 속도가 저하됨 → 확장을 위해 sparse attention kernels 사용 + LSH(locally sensitive hashing) 체계 사용하여 동적으로 패턴 결정

    - 32회의 LSH 전체에서 최소한 k번 일치하는 요소를 선택하고 k는 sparse level이 90%가 되도록 선택

- train dataset
    - musedb
    - 다양한 장르를 가진 200명 아티스트의 3500곡 → 전처리 후 800곡

- 결론
    - 대규모 train dataset으로 훈련하여 Hybrid Demucs SDR을 0.45 dB 능가
    - input 길이는 최대 12.2초까지 확장(Sparse attention tech)

✔ ref

Demucs github

Hybrid Demucs

Hybrid Transformer Demucs